

PONTIFICIA UNIVERSIDAD JAVERIANA

Ciencia de Datos

INFORME TÉCNICO

Proyecto 1 — Técnicas de Aprendizaje de Máquina

*Clasificación de Radiografías de Tórax mediante Redes Neuronales Convolucionales
para la Detección de Enfermedades Pulmonares*

Autores

Juan David Ramírez

Juan Diego Carreño

Docente

Cristian Javier Díaz Álvarez

Bogotá, D.C. — Febrero de 2026

1. Introducción y Contexto del Problema

Las enfermedades pulmonares como la neumonía y el COVID-19 representan una carga crítica para los sistemas de salud a nivel mundial. Su diagnóstico oportuno y preciso es determinante para la evolución clínica del paciente; sin embargo, la interpretación de radiografías de tórax herramienta diagnóstica central en estas condiciones es un proceso subjetivo, influenciado por la experiencia del radiólogo, las condiciones de adquisición de la imagen y la alta demanda asistencial en entornos hospitalarios.

En este contexto, el aprendizaje profundo ofrece una alternativa computacional complementaria capaz de aprender representaciones jerárquicas directamente desde los datos de imagen, sin necesidad de extraer manualmente características clínicas. Las redes neuronales convolucionales (CNN) han demostrado resultados comparables a los de especialistas en múltiples tareas de clasificación médica, particularmente en imágenes de rayos X.

El presente proyecto tiene como objetivo desarrollar un sistema automatizado de clasificación de radiografías de tórax capaz de distinguir entre tres categorías clínicas: pulmón sano (Normal), infección pulmonar bacteriana o viral (Neumonía) y COVID-19. Para ello, se diseñó un pipeline completo que abarca la integración y análisis exploratorio de datos, el preprocesamiento estandarizado de imágenes, el diseño de una arquitectura CNN desde cero, el entrenamiento con estrategias de regularización y la evaluación rigurosa del modelo mediante métricas clínicamente relevantes.

El proyecto fue desarrollado por Juan David Ramírez y Juan Diego Carreño, estudiantes de sexto semestre del pregrado en Ciencia de Datos de la Pontificia Universidad Javeriana, en el marco de la asignatura Técnicas de Aprendizaje de Máquina.

2. Análisis Exploratorio de Datos

El análisis exploratorio de datos (EDA) tiene como propósito caracterizar la distribución, estructura técnica y propiedades estadísticas del conjunto de radiografías de tórax, así como identificar sesgos estructurales que puedan condicionar el diseño del modelo y la interpretación de sus resultados.

2.1 Fuentes de Datos y Construcción del Dataset Unificado

El proyecto integra dos conjuntos de datos públicos disponibles en Kaggle, seleccionados por su relevancia clínica y complementariedad:

- Chest X-ray Images (Pneumonia): contiene radiografías pediátricas clasificadas en pulmón normal y neumonía (bacteriana y viral).
- COVID-19 Radiography Database: contiene radiografías de pacientes adultos con COVID-19, neumonía viral, opacidades pulmonares (Lung Opacity) y pulmones normales.

La integración de ambas fuentes implicó una decisión semántica clave: la unificación de etiquetas en tres clases mutuamente excluyentes. Esta decisión se fundamenta en criterios de coherencia clínica y consistencia estadística:

- La clase Neumonía agrupa neumonía bacteriana, viral y opacidades pulmonares (Lung Opacity). Si bien estas subcategorías presentan diferencias etiológicas, su representación radiológica es suficientemente similar como para que su distinción automática sea clínicamente ambigua y técnicamente difícil de aprender de forma confiable.
- La clase COVID-19 se mantiene separada dada su relevancia epidemiológica específica y su distinto patrón de afectación pulmonar (opacidades en vidrio esmerilado, distribución periférica y bilateral).
- La clase Normal agrupa imágenes de pulmón sin hallazgos patológicos detectables de ambas fuentes.

Esta decisión reduce la ambigüedad semántica entre clases con alta similitud radiológica y permite que el modelo se enfoque en la discriminación clínicamente relevante: pulmón sano vs. infección pulmonar general vs. COVID-19.


2.2 Distribución de Clases

El dataset consolidado contiene 27.021 radiografías distribuidas de la siguiente manera:

Clase	Imágenes	Porcentaje
Normal	11.775	43,6%
Neumonía	11.630	43,0%
COVID-19	3.616	13,4%

Las clases Normal y Neumonía presentan proporciones prácticamente equivalentes, mientras que la clase COVID-19 constituye la fracción minoritaria. Esta distribución introduce un desbalance moderado que tiene implicaciones directas en la estrategia de evaluación: la










exactitud global (accuracy) puede ser engañosa cuando una clase tiene menor representación. Por esta razón, se priorizó el recall por clase y el F1-score macro como métricas de referencia durante la evaluación, especialmente para la clase COVID-19.



2.3 Heterogeneidad Técnica del Dataset

El análisis exploratorio reveló una marcada heterogeneidad estructural en el conjunto de datos. Las resoluciones originales oscilan entre 299×177 y 2.637×2.399 píxeles. Coexisten imágenes en formato PNG y JPEG, y se encuentran tanto imágenes en escala de grises como en RGB. Esta variabilidad, lejos de ser un problema menor, tiene una implicación técnica fundamental: cualquier arquitectura de red neuronal requiere entradas de dimensión fija, por lo que el preprocesamiento de estandarización es una etapa no opcional sino esencial.

Adicionalmente, el análisis de distribuciones de intensidad en escala de grises mostró un alto grado de solapamiento entre clases. No se identificaron desplazamientos sistemáticos de brillo o contraste que permitan distinguir las categorías a partir de estadísticas globales de intensidad. Esto confirma que la discriminación entre clases depende de patrones espaciales y morfológicos complejos precisamente el tipo de información que las CNN están diseñadas para capturar.



2.4 Identificación de Sesgos Estructurales

Se identificaron tres fuentes de sesgo estructural que deben tenerse en cuenta al interpretar el desempeño del modelo:

- Sesgo de definición de etiquetas: la agrupación de múltiples etiologías bajo la clase Neumonía introduce heterogeneidad semántica interna que puede dificultar la discriminación con respecto a otras clases.
- Sesgo de dominio: los datasets provienen de instituciones y equipos de adquisición diferentes (pediátrico vs. adulto, diferentes hospitales), lo que puede introducir variaciones técnicas no relacionadas con la patología que el modelo podría aprender como señales discriminativas espurias.
- Sesgo demográfico: la integración de radiografías pediátricas (dataset de neumonía) con imágenes de población adulta (dataset COVID-19) genera diferencias anatómicas sistemáticas entre clases que podrían ser capturadas por el modelo como patrones no clínicos.

Estos sesgos representan limitaciones estructurales del estudio que condicionan la capacidad de generalización del sistema a poblaciones o entornos de adquisición distintos a los representados en los datos de entrenamiento.

3. Preprocesamiento de Imágenes

El preprocesamiento tiene como finalidad transformar el conjunto heterogéneo de radiografías en un formato homogéneo y compatible con la arquitectura de la red neuronal, reduciendo variaciones técnicas no relacionadas con la patología y garantizando estabilidad numérica durante el entrenamiento. Cada decisión tomada en esta etapa se fundamenta directamente en los hallazgos del análisis exploratorio.

3.1 Estandarización Espacial y de Canales

Todas las imágenes fueron redimensionadas a 224×224 píxeles mediante interpolación bilineal. La elección de esta resolución responde a tres criterios: (1) es el estándar de entrada de arquitecturas CNN ampliamente validadas en visión por computador como VGG, ResNet e Inception; (2) ofrece un balance adecuado entre preservación de detalle anatómico y costo computacional; y (3) elimina la variabilidad de resolución identificada en el EDA, que oscilaba entre tamaños muy pequeños y muy grandes.

Se optó por la interpolación bilineal (`resize_with_pad`) en lugar de un recorte simple, ya que esta estrategia preserva la proporción anatómica de las estructuras pulmonares, evitando distorsiones que podrían comprometer la interpretabilidad de patrones morfológicos relevantes.

Respecto a los canales, las imágenes fueron convertidas a escala de grises y posteriormente replicadas a tres canales. La conversión a escala de grises elimina información cromática que, en radiografías de tórax, no aporta valor diagnóstico y puede introducir variabilidad técnica irrelevante entre escáneres. La replicación a tres canales responde a un requisito de compatibilidad con la arquitectura CNN diseñada, que opera sobre tensores de tres dimensiones.

3.2 Normalización de Intensidades

Los valores de píxel fueron escalados al rango $[0, 1]$ mediante división por 255. Esta operación cumple tres funciones técnicas: (1) reduce el impacto de variaciones globales de luminancia entre imágenes provenientes de distintos equipos; (2) mejora la estabilidad numérica del proceso de optimización, ya que los gradientes durante el backpropagation operan en un rango de valores controlado; y (3) facilita la convergencia del optimizador al operar en una escala uniforme.

Se tomó la decisión deliberada de no aplicar estandarización Z-score ($\text{media}=0$, $\text{desviación estándar}=1$) en esta etapa. Si bien este método es matemáticamente más estricto, la normalización simple a $[0,1]$ preserva la interpretabilidad visual durante la validación del pipeline, lo que fue prioritario dada la naturaleza médica del problema. Esta decisión es coherente con prácticas comunes en la literatura de clasificación de imágenes médicas con CNN entrenadas desde cero.

3.3 Control de Calidad e Integridad de los Datos

Antes del entrenamiento se implementó un procedimiento de validación que verifica la correcta decodificación de cada archivo, la validez de sus dimensiones y su compatibilidad con el pipeline de procesamiento. Tras el filtrado, la totalidad de las 27.021 imágenes resultaron válidas, confirmando la integridad estructural del dataset. Este paso, aunque no produjo descartes, es metodológicamente necesario para garantizar que el proceso de entrenamiento no sea interrumpido por archivos corruptos.

3.4 Partición Estratificada del Dataset

El conjunto de datos se dividió en tres subconjuntos mutuamente excluyentes mediante muestreo estratificado por clase:

Subconjunto	Proporción	Imágenes Aprox.
Entrenamiento	80%	~21.600
Validación	10%	~2.700
Prueba	10%	~2.700

La estratificación garantiza que la proporción de cada clase en particular la clase minoritaria COVID-19 se preserve en los tres subconjuntos. Esto es fundamental para asegurar que el modelo sea evaluado sobre una muestra representativa de la distribución real, evitando que variaciones aleatorias en la composición del conjunto de prueba distorsionen las métricas de evaluación.

La elección de una proporción 80/10/10 responde al volumen total disponible: con más de 27.000 imágenes, el 10% de datos de validación representa ~2.700 muestras, suficiente para estimar el error de generalización con varianza baja.

3.5 Aumento de Datos (Data Augmentation)

Para mejorar la capacidad de generalización del modelo y reducir el riesgo de sobreajuste, se aplicaron transformaciones geométricas y fotométricas controladas exclusivamente al conjunto de entrenamiento. Las transformaciones seleccionadas son:

- Rotaciones leves ($\pm 7,2^\circ$): simulan variaciones en el posicionamiento del paciente al momento de la toma.
- Traslaciones moderadas ($\pm 10\%$): compensan el descentrado de la imagen respecto a la caja torácica.
- Zoom controlado ($\pm 10\%$): emula variaciones en la distancia focal o la proximidad del equipo.
- Variaciones de contraste ($\pm 10\%$): simulan diferencias en la configuración del equipo de rayos X entre instituciones.

Una decisión de diseño relevante en esta etapa fue el uso de relleno reflectante (`fill_mode='reflect'`) en lugar de relleno con ceros. Esta elección evita la introducción de bordes negros artificiales que no existen en radiografías reales, los cuales podrían ser aprendidos como una señal discriminativa espuria por el modelo.

El aumento de datos no se aplica sobre los conjuntos de validación ni de prueba. Esta práctica es fundamental: la validación y la evaluación deben realizarse sobre imágenes sin transformación para que las métricas reflejen fielmente la capacidad del modelo ante datos reales y no modificados.

4. Diseño de la Red Neuronal Convolutacional

El diseño de la arquitectura CNN fue una de las decisiones técnicas centrales del proyecto. Se optó por construir la red desde cero en lugar de emplear una arquitectura preentrenada (transfer learning). Esta elección se fundamenta en el objetivo pedagógico del proyecto comprender en profundidad el funcionamiento de cada capa y en la naturaleza específica de las radiografías de tórax, cuyas características morfológicas difieren significativamente de las imágenes naturales sobre las que fueron entrenados modelos como VGG o ResNet.

4.1 Especificación de Entradas y Salidas

El tensor de entrada tiene dimensión $224 \times 224 \times 3$, correspondiente a imágenes en escala de grises replicadas a tres canales. La capa de salida está compuesta por 3 neuronas con función de activación Softmax, que modela la distribución de probabilidad del diagnóstico sobre las tres clases mutuamente excluyentes: Normal, Neumonía y COVID-19. La activación Softmax garantiza que las salidas sean positivas y sumen 1, lo que permite interpretar directamente cada salida como la probabilidad condicional de la clase dado el input.

4.2 Arquitectura de Bloques Convolucionales Progresivos

La arquitectura sigue un esquema de bloques convolucionales que incrementan progresivamente el número de filtros a medida que disminuye la resolución espacial mediante operaciones de pooling. Esta estrategia es estándar en el diseño de CNN y responde al principio de que a mayor profundidad, el modelo debe capturar representaciones más abstractas y semánticamente ricas.

Bloque	Operación	Filtros / Kernel	Resolución de Salida	Función Aprendida
Bloque 1	Conv2D + MaxPooling	32 filtros, 3×3	112×112	Bordes, contornos y transiciones de intensidad
Bloque 2	Conv2D + MaxPooling	64 filtros, 3×3	56×56	Texturas pulmonares y estructuras anatómicas locales
Bloque 3	Conv2D + MaxPooling	128 filtros, 3×3	28×28	Opacidades difusas y patrones patológicos regionales
Bloque 4	Conv2D + MaxPooling	256 filtros, 3×3	14×14	Representaciones globales de alta abstracción

La elección de kernels 3×3 en todos los bloques se basa en evidencia empírica consolidada en la literatura: múltiples convoluciones 3×3 apiladas capturan el mismo campo receptivo que una

convolución de mayor tamaño (5×5 o 7×7) con menor número de parámetros y mayor no-linealidad efectiva, gracias a la aplicación de ReLU entre capas.

El uso de `padding='same'` mantiene las dimensiones espaciales constantes dentro de cada bloque convolucional, evitando la pérdida de información en los bordes de la imagen. Esto es especialmente relevante en radiografías de tórax, donde hallazgos patológicos periféricos (como en COVID-19) pueden localizarse cerca de los márgenes de la imagen.

La función de activación ReLU se emplea en todas las capas convolucionales e intermedias. Su elección frente a alternativas como Sigmoid o Tanh responde a su capacidad de mitigar el problema del gradiente desvaneciente en redes profundas, su eficiencia computacional y su comportamiento como regularizador implícito al anular activaciones negativas.

4.3 Estrategia de Agregación Espacial: GlobalAveragePooling2D

Tras los cuatro bloques convolucionales, se emplea GlobalAveragePooling2D (GAP) en lugar de la alternativa convencional de Flatten. Esta decisión es deliberada y tiene implicaciones técnicas significativas:

- Reducción drástica de parámetros: GAP colapsa cada mapa de activaciones a un único valor escalar promedio, reduciendo el tensor de salida del último bloque ($14 \times 14 \times 256$) a un vector de 256 valores. La alternativa Flatten produciría un vector de $14 \times 14 \times 256 = 50.176$ dimensiones, multiplicando el número de parámetros en las capas densas subsiguientes.
- Regularización implícita: al forzar al modelo a aprender activaciones distribuidas en todo el mapa espacial, GAP reduce la tendencia al sobreajuste, actuando como una forma de regularización estructural.
- Coherencia con la naturaleza difusa de las patologías: condiciones como COVID-19 y neumonía se manifiestan como opacidades distribuidas en múltiples , no como objetos localizados. GAP es naturalmente compatible con este tipo de patrones al capturar activaciones globales de cada mapa de características.

4.4 Estrategia de Regularización: Dropout

Se implementa Dropout con tasa 0,4 en dos puntos críticos de la red: tras la capa GlobalAveragePooling2D y tras la capa densa intermedia de 128 neuronas. El Dropout desactiva aleatoriamente el 40% de las neuronas en cada paso de entrenamiento, obligando a la red a aprender representaciones redundantes y distribuidas.


La elección de una tasa de 0,4 responde a la heterogeneidad del dataset: la integración de imágenes de distintas instituciones, equipos y poblaciones demográficas crea condiciones propicias para el sobreajuste a patrones técnicos no clínicos. Una tasa de Dropout moderada-alta contrarresta este riesgo sin comprometer excesivamente la capacidad representacional del modelo.

La capa densa intermedia de 128 neuronas actúa como un cuello de botella que fuerza al modelo a aprender combinaciones compactas y no redundantes de las características extraídas por los bloques convolucionales, antes de producir la predicción final.

4.5 Complejidad y Justificación del Tamaño del Modelo

El modelo contiene aproximadamente 421.699 parámetros entrenables. Este tamaño moderado fue una elección deliberada, no una limitación. Con un dataset de ~27.000 imágenes, un modelo excesivamente grande tendería al sobreajuste y requeriría técnicas de regularización

más agresivas. El tamaño propuesto ofrece suficiente capacidad representacional para aprender patrones radiológicos complejos, manteniendo el riesgo de sobreajuste bajo control mediante el Dropout y el aumento de datos aplicados.



5. Entrenamiento y Evaluación del Modelo

5.1 Configuración del Proceso de Optimización

Función de pérdida

Se emplea Sparse Categorical Crossentropy, la función de pérdida estándar para problemas de clasificación multiclase con etiquetas enteras mutuamente excluyentes. Esta función calcula la entropía cruzada entre la distribución de probabilidad predicha por la Softmax y la distribución real (codificada one-hot implícitamente a través del índice de clase), penalizando de forma logarítmica las predicciones incorrectas con alta confianza.

Optimizador: Adam

Se utiliza el optimizador Adam (Adaptive Moment Estimation) con una tasa de aprendizaje inicial de 1×10^{-3} . La elección de Adam sobre alternativas como SGD se fundamenta en su capacidad para adaptar la tasa de aprendizaje de forma individual para cada parámetro, utilizando estimaciones de los primeros y segundos momentos del gradiente. En la práctica, Adam converge más rápidamente que SGD en datasets de imágenes médicas heterogéneos y es menos sensible a la escala de inicialización de los pesos.

5.2 Estrategias de Control del Sobreajuste

Early Stopping

Se configura Early Stopping monitoreando la pérdida de validación con una paciencia de 5 épocas, con restauración de los mejores pesos. Este mecanismo detiene el entrenamiento cuando el modelo deja de generalizar — es decir, cuando la pérdida de validación deja de mejorar — evitando que continúe ajustándose al ruido del conjunto de entrenamiento. La restauración de los mejores pesos garantiza que el modelo final corresponda al punto de mayor capacidad de generalización, no al último paso del entrenamiento.

Reducción Adaptativa de la Tasa de Aprendizaje

Se emplea ReduceLROnPlateau con factor de reducción 0,2 y paciencia de 3 épocas. Cuando la pérdida de validación se estanca, este callback reduce la tasa de aprendizaje al 20% de su valor actual (mínimo 1×10^{-6}), permitiendo búsquedas más finas en el espacio de parámetros. Esta estrategia es complementaria al Early Stopping: mientras el segundo detiene el entrenamiento, el primero intenta superar el estancamiento ajustando la escala de actualización de los pesos.

Checkpoint del Mejor Modelo

Se implementó guardado automático del mejor modelo en Google Drive mediante ModelCheckpoint, monitoreando la pérdida de validación. Esta decisión fue especialmente relevante dada la naturaleza del entorno de ejecución: las sesiones de Google Colab son volátiles y pueden interrumpirse por inactividad o por límites de tiempo de la plataforma. El almacenamiento en Drive garantizó la persistencia del modelo entre sesiones, como se detalla en la sección de dificultades del proyecto.

5.3 Pipeline de Entrenamiento con tf.data

Los conjuntos de datos fueron transformados en objetos `tf.data.Dataset` con procesamiento paralelo mediante `num_parallel_calls=tf.data.AUTOTUNE`. Esta estrategia permite que la lectura y el preprocesamiento de imágenes se realicen en paralelo con el entrenamiento del modelo en GPU, eliminando cuellos de botella de I/O. Se utilizó un tamaño de batch de 32, un valor estándar que equilibra la estabilidad del gradiente (lotes más grandes) con la velocidad de convergencia y el uso de memoria (lotes más pequeños).

El aumento de datos se aplica exclusivamente sobre los lotes de entrenamiento en tiempo real, garantizando que cada época el modelo observe versiones ligeramente distintas de las imágenes y no conjuntos de datos pre-aumentados fijos que podrían ser memorizados.


5.4 Resultados del Entrenamiento

El modelo fue entrenado durante 7 épocas completas — el número máximo configurado — sin que el Early Stopping lo detuviera antes. Este resultado indica que el modelo seguía mejorando consistentemente a lo largo de todo el proceso de entrenamiento, sugiriendo que un número mayor de épocas podría haber producido mejoras adicionales, aunque las restricciones computacionales (descritas en la sección de dificultades) impidieron explorar esta posibilidad.

5.5 Evaluación sobre el Conjunto de Prueba

El modelo fue evaluado sobre el conjunto de prueba (10% de los datos, ~2.700 imágenes) que no participó en el entrenamiento ni en la selección de hiperparámetros. Los resultados obtenidos son los siguientes:

Clase	Precisión	Recall	F1-score	Soporte
COVID-19	0,98	0,77	0,86	~362
Neumonía	0,93	0,87	0,90	~1.163
Normal	0,86	0,96	0,91	~1.178
Promedio macro	0,92	0,87	0,89	—
Promedio ponderado	0,91	0,90	0,90	—
Exactitud global	—	—	—	90%



6. Interpretación de Resultados

6.1 Desempeño Global

El modelo alcanzó una exactitud global del 90% sobre el conjunto de prueba, con un F1-score macro de 0,89 y ponderado de 0,90. Estos resultados indican que el modelo logra una generalización adecuada sobre datos no observados durante el entrenamiento, y que su desempeño es consistente entre las tres clases a pesar del desbalance moderado presente en el dataset.

6.2 Análisis por Clase Clínica

COVID-19 (Precisión: 0,98 | Recall: 0,77 | F1: 0,86)

El modelo presenta la mayor precisión entre las tres clases, lo que significa que cuando predice COVID-19, la predicción es correcta en el 98% de los casos. Sin embargo, el recall de 0,77 indica que el 23% de los casos reales de COVID-19 son clasificados incorrectamente como otras patologías (40 como neumonía, 44 como normal según el análisis de la matriz de confusión).

Esta asimetría entre precisión y recall en la clase COVID-19 es clínicamente relevante: en un contexto diagnóstico real, un bajo recall implica falsos negativos, es decir, pacientes con COVID-19 que serían enviados a casa sin tratamiento específico. Desde la perspectiva clínica, los falsos negativos en COVID son potencialmente más peligrosos que los falsos positivos, lo que sugiere que en aplicaciones reales debería estudiarse la posibilidad de ajustar el umbral de clasificación para privilegiar el recall de esta clase.

La confusión entre COVID-19 y Neumonía es coherente con la similitud radiológica entre estas condiciones: ambas pueden manifestarse como opacidades difusas bilaterales, y su distinción requiere no solo análisis de imagen sino también información clínica adicional (historia de exposición, resultados de laboratorio, etc.).

Neumonía (Precisión: 0,93 | Recall: 0,87 | F1: 0,90)

La clase Neumonía presenta el mejor equilibrio entre precisión y recall. El principal error observado es la clasificación de 148 casos de neumonía como Normal, lo cual puede explicarse en parte por la heterogeneidad semántica de esta clase: la agrupación de neumonías bacterianas, virales y opacidades pulmonares genera un espacio de características intra-clase amplio, donde los casos más leves pueden presentar patrones cercanos a la normalidad radiológica.

Normal (Precisión: 0,86 | Recall: 0,96 | F1: 0,91)

La clase Normal muestra el mayor recall de las tres, indicando que el modelo raramente clasifica como patológicas imágenes sanas. Esto es clínicamente deseable: un sistema de apoyo diagnóstico que frecuentemente alarmara a pacientes sanos generaría saturación del sistema de salud y ansiedad innecesaria. La menor precisión de esta clase (0,86) indica que algunos casos patológicos son incorrectamente clasificados como normales, principalmente de la clase Neumonía.

6.3 Fortalezas y Limitaciones del Modelo

Fortalezas

- Exactitud global del 90% sobre datos heterogéneos provenientes de múltiples fuentes.
- Alta precisión en COVID-19 (0,98), reduciendo al mínimo los falsos positivos en esta clase crítica.
- Excelente sensibilidad para pulmones normales (recall 0,96), apropiada para un sistema de triaje.
- Arquitectura eficiente con ~421.699 parámetros que generaliza adecuadamente sin señales claras de sobreajuste severo.
- Pipeline reproducible y modular que puede adaptarse a nuevas fuentes de datos.

Limitaciones

- Recall moderado en COVID-19 (0,77): aproximadamente 1 de cada 4 casos de COVID-19 es clasificado incorrectamente.
- Heterogeneidad semántica en la clase Neumonía, que agrupa etiologías con patrones radiológicos potencialmente distintos.
- Posible aprendizaje de sesgos de dominio: el modelo podría estar distinguiendo parcialmente por características técnicas de adquisición en lugar de patrones puramente clínicos.
- Diferencias demográficas no controladas entre datasets (población pediátrica vs. adulta).
- Ausencia de validación externa en un dataset completamente independiente de las fuentes utilizadas.

7. Dificultades y Retos del Proyecto

El desarrollo de este proyecto implicó enfrentar una serie de retos técnicos y operativos significativos que condicionaron las decisiones tomadas y el proceso de trabajo. Su documentación es relevante no solo para contextualizar los resultados, sino para identificar áreas de mejora en futuros trabajos.

7.1 Limitaciones de Cómputo en Google Colab Gratuito

El reto más crítico del proyecto fue la restricción computacional impuesta por el uso de Google Colab en su versión gratuita. Esta plataforma asigna GPUs de forma dinámica y con disponibilidad limitada; en ausencia de GPU, el entrenamiento recae sobre CPU, lo cual impacta severamente los tiempos de procesamiento.

En nuestro caso, el entrenamiento del modelo requirió aproximadamente 20 horas en total. Este tiempo, significativamente superior al esperado para una red de tamaño moderado (~421.699 parámetros) sobre un dataset de 27.000 imágenes, se explica por la combinación de varios factores: la asignación intermitente de recursos de GPU en la versión gratuita de Colab, el procesamiento en paralelo limitado disponible en sesiones sin GPU dedicada, el tamaño de las imágenes ($224 \times 224 \times 3$), el pipeline de aumento de datos aplicado en tiempo real sobre cada batch, y las fases de lectura y decodificación de archivos desde el sistema de archivos de Colab.

Esta restricción tuvo consecuencias directas sobre las decisiones de diseño: el número de épocas se limitó a 7 lejos del potencial de mejora que podría haberse explorado con más tiempo y no fue posible realizar búsquedas sistemáticas de hiperparámetros (learning rate, batch size, arquitectura) dado el costo prohibitivo en tiempo de cada experimento.

7.2 Gestión de Sesiones y Pérdida de Progreso

Google Colab desconecta automáticamente las sesiones por inactividad o al exceder los límites de tiempo de uso gratuito. Durante el proceso de entrenamiento de 20 horas, se produjeron desconexiones de sesión que interrumpieron el proceso. Para mitigar este riesgo, se implementó una solución de persistencia basada en Google Drive: el callback `ModelCheckpoint` guardó automáticamente la versión del modelo con mejor pérdida de validación en una carpeta de Drive al final de cada época. De esta forma, al reiniciar una sesión tras una desconexión, era posible retomar el entrenamiento desde el último checkpoint guardado, cargando el modelo y continuando con las épocas restantes.

Esta solución, si bien efectiva, implica una sobrecarga de tiempo adicional: cada checkpoint requiere serializar y transferir el modelo completo a Drive, lo que añade latencia al final de cada época. En proyectos futuros con restricciones similares, se recomendaría evaluar el uso de Colab Pro, el acceso a clústeres universitarios con GPU dedicada, o plataformas como Kaggle Notebooks o Paperspace Gradient, que ofrecen recursos más estables y prolongados.

7.3 Heterogeneidad y Unificación de Datasets

La integración de dos datasets con estructuras, nomenclaturas de carpetas, formatos de imagen y distribuciones demográficas distintas requirió un trabajo cuidadoso de ingeniería de datos. La resolución de las discrepancias semánticas entre etiquetas — en particular, la decisión de agrupar Lung Opacity y Viral Pneumonia bajo la clase Neumonía — implicó una

revisión de la literatura clínica y una justificación metodológica que va más allá del procesamiento técnico. Esta etapa fue más costosa en tiempo de lo anticipado inicialmente.

7.4 Desbalance de Clases y Estrategia de Evaluación

La clase COVID-19 representa solo el 13,4% del dataset total, lo que introduce el riesgo de que las métricas globales (accuracy) sean engañosas al enmascarar el desempeño real sobre la clase minoritaria. Identificar esta limitación desde el EDA y diseñar la estrategia de evaluación en consecuencia priorizando recall y F1 por clase fue un ejercicio de pensamiento crítico necesario que añadió complejidad al análisis de resultados.

7.5 Ausencia de Información sobre el Proceso de Entrenamiento

Dado que varias sesiones de entrenamiento fueron reiniciadas por desconexiones, no se pudo conservar el historial completo de pérdida y exactitud por época de forma continua. Esto imposibilitó la generación de curvas de aprendizaje (training/validation loss por época) que habrían permitido un análisis más detallado del comportamiento de convergencia y la detección temprana de señales de sobreajuste. En futuros proyectos, se recomienda integrar herramientas de logging persistente como Weights & Biases o TensorBoard con almacenamiento en la nube.

8. Conclusiones del Proyecto

En este proyecto se desarrolló un sistema de clasificación automática de radiografías de tórax basado en una red neuronal convolucional diseñada desde cero, capaz de distinguir entre tres categorías clínicas: Normal, Neumonía y COVID-19. El pipeline completo, que abarca integración de múltiples fuentes de datos, preprocesamiento estandarizado, diseño arquitectónico, entrenamiento con regularización y evaluación rigurosa, demostró ser una solución funcional y reproducible.

El modelo alcanzó una exactitud global del 90% sobre el conjunto de prueba, con F1-score macro de 0,89. Destacan en particular la alta precisión en la detección de COVID-19 (0,98) y la excelente sensibilidad para identificar pulmones sanos (recall 0,96). El análisis de errores revela que los casos de clasificación incorrecta se concentran principalmente entre COVID-19 y Neumonía, lo cual es consistente con la similitud radiológica conocida entre estas patologías.

Los resultados validan la efectividad del diseño del pipeline de preprocesamiento y de la arquitectura propuesta para aprender representaciones útiles en un entorno de datos realista y heterogéneo. Al mismo tiempo, el proceso completo reforzó la importancia del pensamiento crítico en cada etapa: desde la unificación semántica de etiquetas hasta la selección de métricas de evaluación apropiadas para un dataset con desbalance de clases.

Es fundamental enfatizar que el sistema desarrollado tiene carácter experimental y no puede considerarse un sistema de diagnóstico clínico. Su utilidad debe entenderse como la de una herramienta de apoyo que puede asistir al especialista, no reemplazarlo, y únicamente en el contexto de los datos y condiciones bajo las cuales fue entrenado.

Referencias

- Chowdhury, M. E. H., et al. (2020). Can AI Help in Screening Viral and COVID-19 Pneumonia? IEEE Access, 8, 132665–132676.
- Mooney, P. (2018). Chest X-Ray Images (Pneumonia). Kaggle Dataset. <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>
- Rahman, T. (2021). COVID-19 Radiography Database. Kaggle Dataset. <https://www.kaggle.com/datasets/tawsifurrahman/covid19-radiography-database>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436–444.
- Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications.
- Srivastava, N., et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research, 15(1), 1929–1958.
- Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. ICLR 2015.
- He, K., et al. (2016). Deep Residual Learning for Image Recognition. CVPR 2016.
- Google. (2026). Gemini (versión 3.1 Pro) [Modelo de lenguaje de IA]. <https://gemini.google.com/>
- OpenAI. (2026). ChatGPT (versión GPT 5.2) [Modelo de lenguaje de IA]. <https://chat.openai.com/>
- Anthropic. (2026). Claude 4.6 Sonnet (Modelo de lenguaje de gran tamaño) [IA generativa]. <https://claude.ai/>