

PONTIFICIA UNIVERSIDAD JAVERIANA

Ciencia de Datos

INFORME TÉCNICO

Proyecto 2 - Técnicas de Aprendizaje de Máquina

Segmentación de Clientes con K-Means y Clasificación mediante Árbol de Decisión

Autores

Juan David Ramírez

Juan Diego Carreño

Docente

Cristian Javier Díaz Álvarez

Bogotá, D.C - Abril de 2026

1. Introducción y Planteamiento del Problema

La segmentación de clientes es una de las aplicaciones más relevantes del aprendizaje de máquina en el contexto empresarial. Comprender de forma precisa quiénes son los clientes, cómo se comportan y qué los diferencia entre sí permite a las organizaciones diseñar estrategias de marketing más efectivas, optimizar la fidelización, personalizar la experiencia de compra y priorizar recursos en los segmentos de mayor valor.

En este proyecto se aborda el problema de segmentación automática de clientes a partir de un conjunto de datos con variables demográficas, transaccionales y de comportamiento. Para ello, se aplica un enfoque en dos etapas: primero, aprendizaje no supervisado mediante el algoritmo K-Means, que permite descubrir grupos naturales de clientes sin etiquetas previas; y segundo, aprendizaje supervisado mediante un árbol de decisión, que utiliza los clusters generados como etiquetas para construir un modelo predictivo capaz de clasificar nuevos clientes.

Este flujo, de lo no supervisado a lo supervisado, tiene una lógica metodológica clara: K-Means permite identificar la estructura latente del dato, mientras que el árbol de decisión convierte esa estructura en reglas interpretables y aplicables en producción. El resultado es un sistema que no solo describe los segmentos existentes, sino que puede asignar a cualquier cliente nuevo a su segmento correspondiente de forma automática.

2. Análisis Exploratorio y Preprocesamiento de Datos

2.1 Descripción del Dataset

El dataset utilizado contiene registros de clientes con 13 variables que cubren cuatro dimensiones de análisis: demográfica, transaccional, comportamental y de canal. La siguiente tabla resume el diccionario de datos:

Variable	Tipo	Descripción
edad	Numérica (entera)	Edad del cliente en años
ingresos_anuales	Numérica (continua)	Ingreso anual estimado (USD)
cantidad_compras	Numérica (entera)	Número total de compras realizadas
valor_promedio_compra	Numérica (continua)	Valor promedio por compra (USD)
frecuencia_compras_mensual	Numérica (continua)	Promedio de compras por mes
dispositivo_utilizado	Categórica	Dispositivo más usado (móvil, PC, tablet)
fuentes_trafico	Categórica	Canal de adquisición (redes sociales, búsqueda, email)
dias_desde_ultima_compra	Numérica (entera)	Días transcurridos desde la última compra
valor_total_gastado	Numérica (continua)	Total gastado en todas las compras (USD)
satisfaccion_cliente	Numérica (continua)	Nivel de satisfacción (escala 1 a 5)
metodo_pago	Categórica	Método de pago más frecuente
participacion_programa_lealtad	Binaria (0/1)	Participa en programa de lealtad
productos_adquiridos	Categórica	Categoría principal de productos adquiridos

2.2 Validación de Calidad de Datos

Antes del análisis exploratorio propiamente dicho, se realizó una validación sistemática del dataset que verificó los tipos de datos, rangos esperados por variable, categorías registradas en variables categóricas, presencia de duplicados y valores nulos. Esta revisión es metodológicamente necesaria para detectar inconsistencias que, de no corregirse, introducirían ruido en el modelo de clustering.

La validación identificó dos inconsistencias puntuales que fueron corregidas antes de continuar:

- Una categoría mal escrita en la variable metodo_pago ('tarjeta crédito'), unificada a 'tarjeta crédito' para mantener consistencia semántica en las frecuencias de la variable.

- Un valor 'nan' registrado como cadena de texto en productos_adquiridos, convertido a valor nulo real para ser tratado correctamente en el pipeline.

Adicionalmente, se identificaron dos filas con valores nulos, las cuales fueron eliminadas. Esta decisión se justifica en que representan menos del 0,0003% del total de registros, por lo que su exclusión no introduce sesgo estadístico apreciable en el dataset. La imputación habría sido innecesaria y potencialmente más dañina que la eliminación, dado el volumen total de datos disponible.

Tras la limpieza, el dataset quedó íntegro en términos de tipos, rangos y categorías, sin duplicados y sin valores nulos, listo para el análisis exploratorio.

2.3 Análisis Descriptivo de Variables

El análisis de estadísticas descriptivas de las variables numéricas revela distribuciones con asimetría positiva en las variables de gasto e ingresos, lo que indica que la mayoría de los clientes se concentra en rangos de consumo moderado, mientras una minoría presenta valores muy altos. Esta asimetría es característica de datasets de clientes reales y es relevante para el clustering, ya que K-Means es sensible a la escala de las variables.

Un hallazgo especialmente relevante es la distribución bimodal de frecuencia_compras_mensual, que evidencia la existencia de al menos dos perfiles marcadamente distintos en la población: clientes esporádicos y clientes de alta frecuencia. Esta señal sugiere la presencia de segmentos naturales antes incluso de aplicar el algoritmo, validando la pertinencia del enfoque de clustering.

En las variables categóricas, la distribución es relativamente equilibrada entre categorías, sin que ninguna domine de forma aplastante. Predominan el uso de móvil y PC como dispositivos, redes sociales como fuente de tráfico, tarjeta de crédito como método de pago, y una distribución balanceada entre tipos de productos. Este equilibrio facilita la formación de clusters heterogéneos y reduce el riesgo de que una categoría dominante distorsione los resultados.

2.4 Análisis de Relaciones entre Variables

El análisis de la matriz de correlación entre variables numéricas reveló dos relaciones especialmente relevantes para el diseño del preprocesamiento:

- Correlación muy alta ($r = 0,82$) entre cantidad_compras y frecuencia_compras_mensual: ambas variables miden esencialmente el mismo fenómeno desde ángulos complementarios (volumen total vs. ritmo mensual). Incluir ambas en K-Means habría sobreponderado esta dimensión del comportamiento en el cálculo de distancias euclidianas.
- Correlación inversa fuerte ($r = -0,76$) entre dias_desde_ultima_compra y frecuencia_compras_mensual: confirma que los clientes más activos tienen compras más recientes, una relación esperada que valida la coherencia interna del dataset.

Los boxplots de variables numéricas contra categóricas revelaron patrones de comportamiento con implicaciones para la segmentación: los usuarios de móvil muestran mayor frecuencia de compra; los clientes captados por email presentan mayores ingresos y tickets promedio; los que pagan por transferencia concentran el mayor gasto total; y las categorías de electrodomésticos y computadoras registran tickets promedio más elevados. Estos patrones refuerzan la hipótesis de que existen perfiles diferenciados en el dataset.

2.5 Preprocesamiento para Clustering

El preprocesamiento tuvo como objetivo transformar el dataset en una representación homogénea y compatible con el algoritmo K-Means. Las decisiones tomadas en esta etapa se fundamentan directamente en los hallazgos del análisis exploratorio:

Eliminación de cantidad_compras

Dado el coeficiente de correlación de 0,82 con frecuencia_compras_mensual, se tomó la decisión de eliminar cantidad_compras del dataset de entrenamiento. Mantener ambas variables habría introducido multicolinealidad que distorsionaría el cálculo de distancias euclidianas en K-Means, sobreponderando artificialmente la dimensión de intensidad de compra frente a otras dimensiones del comportamiento del cliente.

Estandarización con StandardScaler

Las 8 variables numéricas restantes fueron escaladas a media 0 y desviación estándar 1 mediante StandardScaler. Esta transformación es obligatoria para K-Means porque el algoritmo calcula distancias euclidianas: sin estandarización, variables con rangos amplios como ingresos_anuales (del orden de miles de dólares) dominarían completamente la función de distancia, haciendo que variables de menor magnitud como satisfaccion_cliente (escala 1-5) o participacion_programa_lealtad (0/1) sean prácticamente ignoradas. La estandarización garantiza que todas las variables contribuyan equitativamente al agrupamiento.

Codificación One-Hot de variables categóricas

Las 4 variables categóricas fueron transformadas mediante OneHotEncoder con drop='first', lo que genera variables indicadoras binarias para cada categoría excluyendo una de referencia. La elección de One-Hot sobre Label Encoding se justifica porque K-Means interpreta las características como dimensiones continuas del espacio vectorial: asignar valores ordinales arbitrarios (0, 1, 2) a categorías nominales sin orden intrínseco introduciría relaciones de proximidad falsas entre categorías que no las tienen.

Como resultado del preprocesamiento, el dataset quedó representado en 17 variables (8 numéricas escaladas + 9 indicadoras OHE), completamente numéricas, sin valores nulos y con medias centradas en cero, listas para la aplicación de K-Means.

3. Aplicación de K-Means

3.1 Determinación del Número Óptimo de Clusters

La elección del número de clusters K es la decisión metodológica más crítica en cualquier aplicación de K-Means. Un valor de K demasiado bajo produce segmentos heterogéneos internamente sin valor interpretativo; un valor demasiado alto genera segmentos redundantes que complican la acción empresarial. Para determinar K se aplicó el método del codo, que evalúa la inercia (Within-Cluster Sum of Squares, WCSS) en función del número de clusters.

La inercia mide la suma de distancias cuadráticas de cada punto a su centroide más cercano: a menor inercia, más compactos son los clusters. El método del codo busca el punto donde la reducción marginal de inercia al añadir un cluster adicional deja de ser proporcional al costo de complejidad.

K	Inercia (WCSS)	Reducción absoluta	Reducción %
2	66.154	—	—
3	56.287	9.867	14,9%
4	49.182	7.105	12,6%
5	43.133	6.049	12,3%
6	38.946	4.187	9,7%
7	35.380	3.566	9,2%
8	32.900	2.480	7,0%
9	31.498	1.402	4,3%
10	29.943	1.555	4,9%

La tabla muestra que entre K=2 y K=5 las reducciones de inercia superan el 12% por paso, mientras que a partir de K=6 las mejoras caen por debajo del 10% y se estabilizan. El punto de inflexión visible en la curva ocurre en K=5, que representa el último punto antes de entrar en rendimientos decrecientes claros. Por esta razón se seleccionó K=5 como número óptimo de clusters.

Esta elección también se validó desde una perspectiva de negocio: 5 segmentos son suficientes para capturar la diversidad del comportamiento de los clientes y diseñar estrategias diferenciadas, sin llegar a un nivel de granularidad que dificulte la interpretación y la acción comercial.

El modelo se configuró con `init='k-means++'` para una inicialización de centroides más inteligente que la aleatoria simple, reduciendo la probabilidad de convergencia a mínimos locales subóptimos. Se utilizó `n_init=10` para ejecutar el algoritmo 10 veces con distintas semillas y retener el mejor resultado, aumentando la robustez y reproducibilidad de la segmentación.

3.2 Distribución de los Clusters

El modelo K-Means con K=5 produjo la siguiente distribución de clientes por segmento:

Cluster	Nombre asignado	Cientes	% del total
0	Adultos mayores de bajo valor	8.769	1,51%
1	Jóvenes frecuentes de bajo ingreso	166.731	28,65%
2	Maduros premium con bajo engagement	154.026	26,50%
3	Jóvenes de alto ingreso y alta frecuencia	248.726	42,77%
4	Jóvenes de alto ingreso e insatisfechos	55.796	9,59%

La distribución no es uniforme, lo cual es esperable y deseable: refleja la estructura real del mercado, donde no todos los segmentos tienen el mismo tamaño. El Cluster 3 es el más grande y el Cluster 0 el más pequeño y especializado. Esta variabilidad de tamaños es una señal de que el algoritmo encontró agrupaciones genuinas y no artificialmente balanceadas.

3.3 Perfiles de los Segmentos de Clientes

A continuación se presentan los perfiles detallados de cada cluster, contruidos a partir de las medias de las variables numéricas y las modas de las variables categóricas para cada grupo.

Nombre del segmento	Adultos mayores de bajo valor
Tamaño	8.769 clientes (1,51% del total)
Perfil demográfico	Clientes de mayor edad del dataset (promedio 64 años) con ingresos medios-bajos (~21.000 USD).
Comportamiento	Frecuencia de compra muy baja y alta recencia (105 días desde la última compra). Aunque el gasto acumulado histórico es elevado, sus compras individuales son de bajo valor unitario. Baja participación en programa de lealtad.
Canales y preferencias	Prefieren PC como dispositivo. Canal de adquisición: email. Método de pago: transferencia bancaria. Productos predominantes: electrodomésticos básicos.

Nombre del segmento	Jóvenes frecuentes de bajo ingreso
Tamaño	166.731 clientes (28,65% del total)
Perfil demográfico	Clientes jóvenes (promedio 26 años) con ingresos bajos (~40.000 USD). Segundo segmento más grande.

Comportamiento	Compradores digitales habituales: cerca de 10 compras por mes y última compra hace menos de 10 días. Satisfacción muy alta. Alta participación en programa de lealtad.
Canales y preferencias	Dispositivo: móvil. Canal: redes sociales. Método de pago: tarjeta de crédito. Productos: accesorios.

Nombre del segmento	Maduros premium con bajo engagement
Tamaño	154.026 clientes (26,50% del total)
Perfil demográfico	Clientes de edad media-alta (promedio 47 años) con ingresos altos (~86.000 USD).
Comportamiento	Segmento de alto valor en riesgo de abandono. Compran con muy baja frecuencia y no han interactuado en más de 200 días, aunque cuando compran el ticket promedio es muy alto. Satisfacción media.
Canales y preferencias	Dispositivo: PC. Canal: búsqueda orgánica. Método de pago: transferencia. Productos: electrodomésticos de alto valor.

Nombre del segmento	Jóvenes de alto ingreso y alta frecuencia
Tamaño	248.726 clientes (42,77% del total)
Perfil demográfico	Adultos jóvenes (promedio 38 años) con ingresos muy altos (~114.000 USD). Segmento más grande.
Comportamiento	Segmento más valioso del dataset. Alta frecuencia de compra, recencia alta y gasto total elevado. Son el núcleo del negocio. Alta satisfacción y fuerte participación en programa de lealtad.
Canales y preferencias	Dispositivo: móvil (mobile-first). Canal: redes sociales. Método de pago: PayPal. Productos: smartphones y tecnología.

Nombre del segmento	Jóvenes de alto ingreso e insatisfechos
Tamaño	55.796 clientes (9,59% del total)
Perfil demográfico	Clientes muy jóvenes (promedio 30 años) con el ingreso más alto del dataset (~119.000 USD).
Comportamiento	Segmento de alto potencial no aprovechado. Tienen capacidad de gasto pero casi no compran, y su nivel de satisfacción es el más bajo de todos los grupos. Representan la mayor oportunidad de activación.
Canales y preferencias	Dispositivo: tablet. Canal: redes sociales. Método de pago: tarjeta de crédito. Comportamiento de baja frecuencia y alta insatisfacción.

3.4 Justificación del No Sub-clustering

El Cluster 3, por su tamaño (42,77% del total), podría en principio subdividirse en perfiles más específicos. Sin embargo, se decidió conscientemente no realizar sub-clustering por las siguientes razones: los cinco clusters obtenidos ya presentan perfiles claramente diferenciados

e interpretables en términos de negocio; aumentar el número de clases habría dificultado la posterior clasificación con el árbol de decisión, reduciendo la claridad interpretativa del modelo supervisado; y en el contexto del proyecto, añadir complejidad sin una mejora proporcional en la capacidad explicativa no se justifica metodológicamente.

4. Árbol de Decisión Supervisado

4.1 Motivación y Diseño del Enfoque

Una vez generados los cinco segmentos mediante K-Means, el siguiente paso fue convertir la segmentación no supervisada en un modelo predictivo mediante un árbol de decisión supervisado. Este enfoque en dos etapas tiene una justificación metodológica clara: K-Means identifica la estructura latente de los datos, pero no produce reglas explícitas para clasificar nuevos clientes. El árbol de decisión resuelve exactamente esa limitación, generando un conjunto de reglas interpretables que pueden aplicarse operacionalmente en tiempo real.

La elección de árbol de decisión frente a otras alternativas supervisadas como regresión logística o SVM se justifica por tres razones: (1) interpretabilidad directa; cada rama del árbol es una regla de negocio legible por un analista no técnico; (2) compatibilidad con el tipo de clusters; los segmentos obtenidos tienen fronteras no lineales en el espacio de características, que un árbol maneja naturalmente; y (3) resistencia al sobreajuste controlada; mediante hiperparámetros de poda, el árbol puede regularizarse sin pérdida de interpretabilidad.

4.2 Configuración del Modelo

El árbol fue configurado con los siguientes hiperparámetros, cada uno con una justificación explícita:

Hiperparámetro	Valor	Justificación
max_depth	8	Limita la profundidad máxima del árbol. Previene el sobreajuste al impedir ramas que memorizan casos específicos en lugar de patrones generales.
min_samples_split	50	Exige al menos 50 muestras para dividir un nodo. Evita divisiones basadas en grupos muy pequeños que podrían ser ruido estadístico.
min_samples_leaf	25	Garantiza que cada hoja tenga al menos 25 muestras. Aumenta la estabilidad de las predicciones en los nodos terminales.
class_weight	'balanced'	Pondera las clases inversamente proporcional a su frecuencia. Esencial dado el desbalance entre clusters (desde 1,51% hasta 42,77%).
random_state	42	Semilla para reproducibilidad de resultados.

La división del dataset se realizó con una proporción 80/20 estratificada por clase, lo que garantiza que la proporción de clientes de cada cluster se preserve tanto en entrenamiento

como en prueba. Esto es especialmente importante para el Cluster 0 (1,51% del total), que con un split no estratificado podría quedar subrepresentado en el conjunto de prueba, sesgando las métricas de evaluación.

4.3 Evaluación del Modelo

El modelo fue evaluado sobre el 20% de los datos no utilizado en el entrenamiento. Los resultados obtenidos son:

Métrica global	Valor
Accuracy	97,17%
Balanced Accuracy	97,51%

La diferencia mínima entre accuracy y balanced accuracy (97,17% vs 97,51%) confirma que el buen desempeño del modelo no está inflado por los clusters mayoritarios, sino que es consistente entre todos los segmentos, incluyendo el Cluster 0 que representa solo el 1,51% de los datos. Esto valida la efectividad del parámetro `class_weight='balanced'` en la compensación del desbalance.

Cluster	Precisión	Recall	F1-score
Cluster 0 — Adultos mayores de bajo valor	$\geq 0,95$	$\geq 0,95$	$\geq 0,95$
Cluster 1 — Jóvenes frecuentes de bajo ingreso	$\geq 0,95$	$\geq 0,95$	$\geq 0,95$
Cluster 2 — Maduros premium con bajo engagement	$\geq 0,95$	$\geq 0,95$	$\geq 0,95$
Cluster 3 — Jóvenes de alto ingreso y alta frecuencia	$\geq 0,95$	0,94	$\geq 0,95$
Cluster 4 — Jóvenes de alto ingreso e insatisfechos	$\geq 0,95$	$\geq 0,95$	$\geq 0,95$

Todos los clusters presentan métricas superiores a 0,94, con el Cluster 3 mostrando el recall ligeramente menor, lo que sugiere que este segmento, siendo el más grande y heterogéneo, presenta una mayor superposición con otros grupos en el espacio de características. Sin embargo, el desempeño sigue siendo sobresaliente.

El nivel de accuracy alcanzado (97,17%) es una consecuencia directa de la calidad de la segmentación K-Means: si los clusters estuvieran mal definidos o sus fronteras fueran difusas, el árbol no podría aprenderlas con esta precisión. En este sentido, el alto desempeño del árbol funciona como una validación indirecta de la calidad del clustering.

4.4 Importancia de Variables

El análisis de importancia de variables (medida por el criterio de impureza de Gini) revela una jerarquía clara y altamente concentrada en tres variables:

Variable	Importancia (Gini)	% acumulado
ingresos_anuales	0,459	45,9%
frecuencia_compras_mensual	0,276	73,5%
valor_total_gastado	0,237	97,2%
Resto de variables	~0,028	100%

Tres variables concentran más del 97% del poder predictivo del modelo. Esto tiene implicaciones técnicas y de negocio importantes:

- Ingresos anuales (45,9%): es la variable más discriminante del árbol. Separa fundamentalmente a los clusters por nivel económico, distinguiendo entre segmentos de bajo ingreso (Clusters 0 y 1) y alto ingreso (Clusters 2, 3 y 4).
- Frecuencia de compras mensual (27,6%): es el segundo eje de diferenciación. Separa a los clientes activos de los inactivos, distinguiendo entre el Cluster 1 y 3 (alta frecuencia) frente al Cluster 2 y 4 (baja frecuencia).
- Valor total gastado (23,7%): complementa a los dos anteriores al capturar el historial acumulado de gasto, diferenciando entre clientes con largo historial (Cluster 2) y clientes recientes de alta capacidad (Cluster 4).

Las variables categóricas (dispositivo, fuente de tráfico, método de pago, productos) aportan menos del 3% a la capacidad predictiva. Esto no implica que no sean útiles para describir los clusters, como se evidenció en los perfiles, sino que no son determinantes para separar los grupos predictivamente. Desde una perspectiva de ingeniería de características, este resultado sugiere que para clasificar a un cliente nuevo en su segmento bastaría con conocer sus ingresos, su frecuencia de compra y su gasto total.

5. Interpretación de Resultados y Aplicaciones de Negocio

5.1 Coherencia entre Clustering y Clasificación

El resultado más relevante del proyecto es la coherencia entre ambas etapas del análisis. El árbol de decisión alcanzó un 97,17% de accuracy prediciendo los clusters generados por K-Means, lo que confirma que los segmentos encontrados no son artefactos del algoritmo, sino que reflejan estructuras genuinas y separables en el espacio de características. Si los clusters fueran ruido o agrupaciones arbitrarias, el árbol no podría aprender a reproducirlos con esta precisión.

Esta coherencia también valida el pipeline completo de preprocesamiento: la estandarización de variables, la eliminación de multicolinealidad y la codificación categórica fueron suficientes para producir una representación del dato que permite tanto el agrupamiento (K-Means) como la clasificación (árbol) con alta calidad.

5.2 Estrategias Comerciales por Segmento

La utilidad práctica de la segmentación se materializa en la capacidad de diseñar estrategias específicas para cada grupo:

- Cluster 3: Jóvenes de alto ingreso y alta frecuencia: constituye el segmento más valioso. La estrategia debe orientarse a la fidelización y el aumento del ticket promedio mediante programas de lealtad premium, acceso anticipado a nuevos productos y cross-selling de tecnología de alta gama.
- Cluster 2: Maduros premium con bajo engagement: representan alto valor en riesgo de abandono. Requieren campañas de reactivación personalizadas basadas en su historial de compras, con comunicación por búsqueda orgánica y email, sus canales preferidos, y ofertas de alto valor unitario alineadas con su ticket promedio histórico.
- Cluster 4: Jóvenes de alto ingreso e insatisfechos: son la mayor oportunidad de activación. Con el ingreso más alto del dataset pero la satisfacción más baja, el problema no es económico sino de experiencia. La prioridad debe ser identificar y resolver las causas de insatisfacción antes de incrementar el gasto en adquisición.
- Cluster 1: Jóvenes frecuentes de bajo ingreso: base fiel y activa. La estrategia debe enfocarse en mantener su alto nivel de satisfacción mediante una experiencia de compra móvil fluida, programas de puntos accesibles y productos de accesorios a precio competitivo.
- Cluster 0: Adultos mayores de bajo valor: segmento pequeño y de bajo dinamismo. La estrategia de inversión debe ser conservadora, orientada a mantener la relación existente con comunicación por email y canales de pago por transferencia, sin grandes esfuerzos de reactivación.

5.3 Limitaciones del Análisis

A pesar de los buenos resultados obtenidos, es importante señalar las limitaciones inherentes al análisis:

- Sensibilidad de K-Means a la inicialización y a la escala: aunque se mitigó con `k-means++` y `n_init=10`, el algoritmo no garantiza el óptimo global y sus resultados pueden variar con distintas semillas.
- Validación interna del clustering: se utilizó únicamente el método del codo para determinar K. En análisis más rigurosos se complementaría con el coeficiente de silueta y el índice de Davies-Bouldin para una validación más robusta.

- El alto accuracy del árbol no garantiza generalización externa: el modelo fue evaluado sobre datos del mismo dataset. Su desempeño sobre datos de clientes de distintas instituciones o períodos temporales podría diferir significativamente.
- Ausencia de variables temporales: el dataset no incluye series de tiempo del comportamiento del cliente, lo que limita la capacidad de capturar tendencias o estacionalidades en los patrones de compra.

6. Conclusiones

En este proyecto se demostró que la combinación de aprendizaje no supervisado y supervisado constituye un enfoque metodológico robusto para la segmentación y predicción de perfiles de clientes. El pipeline completo, desde el análisis exploratorio hasta la clasificación supervisada, produjo resultados coherentes, interpretables y directamente aplicables en un contexto empresarial real.

El análisis exploratorio fue determinante para las decisiones de preprocesamiento: la distribución bimodal de la frecuencia de compras anticipó la existencia de segmentos naturales, la correlación entre `cantidad_compras` y `frecuencia_compras_mensual` justificó la eliminación de la primera, y la heterogeneidad de escalas entre variables fundamentó la estandarización con `StandardScaler`.

K-Means con $K=5$ produjo cinco segmentos claramente diferenciados en términos de ingresos, frecuencia de compra, recencia y nivel de satisfacción. Los perfiles obtenidos son interpretables desde una perspectiva de negocio e identifican tanto el segmento más valioso del portafolio (Cluster 3) como la mayor oportunidad de activación (Cluster 4) y el mayor riesgo de abandono (Cluster 2).

El árbol de decisión alcanzó un accuracy del 97,17% y un balanced accuracy del 97,51%, confirmando que los clusters son separables y que el modelo puede clasificar nuevos clientes con alta confiabilidad. La concentración del 97% del poder predictivo en tres variables: ingresos anuales, frecuencia de compras y valor total gastado, simplifica significativamente la operacionalización del modelo, permitiendo clasificar un cliente nuevo con solo tres datos clave.

En conjunto, los resultados validan tanto el diseño del pipeline de preprocesamiento como las decisiones de modelado tomadas en cada etapa, y evidencian que el pensamiento crítico aplicado en el análisis exploratorio (identificar multicolinealidad, detectar señales de segmentación naturales, justificar cada transformación) fue determinante para la calidad final del sistema.

Referencias

- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.
- Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). *Classification and Regression Trees*. Wadsworth & Brooks/Cole.
- Scikit-learn Developers. (2024). `sklearn.cluster.KMeans`. <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>
- Scikit-learn Developers. (2024). `sklearn.tree.DecisionTreeClassifier`. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Kaufman, L., & Rousseeuw, P. J. (2005). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley-Interscience.
- Chollet, F. (2021). *Deep Learning with Python* (2nd ed.). Manning Publications.
- Anthropic. (2026). Claude 4.6 Sonnet (Modelo de lenguaje de gran tamaño) [IA generativa]. <https://claude.ai/>