

Predicción del Nivel de Alerta del Conductor

Por Juan Diego Carreño Vásquez

*Fundamentos de Aprendizaje de Máquina - Ciencia de Datos
Pontificia Universidad Javeriana*

1. Entendimiento de negocio

El objetivo del taller fue desarrollar un modelo predictivo capaz de estimar la probabilidad de que un conductor estuviera alerta mientras manejaba en condiciones reales. La competencia fue evaluada en Kaggle mediante la métrica ROC-AUC, por lo que el problema se abordó como una tarea de clasificación binaria enfocada en maximizar la capacidad de discriminación probabilística del modelo y no únicamente la exactitud.

Las variables disponibles incluían información fisiológica, hábitos de sueño, consumo de alcohol y condiciones del entorno vial. Desde el inicio se consideró que el problema tendría relaciones no lineales importantes entre variables, especialmente entre sueño, fatiga y tiempo despierto, por lo que se decidió combinar modelos lineales interpretables con métodos de boosting basados en árboles.

2. Entendimiento de los datos

El conjunto de entrenamiento contenía aproximadamente 350 mil registros con 11 variables numéricas y una variable objetivo binaria ('is_alert'). El conjunto de predicción contenía cerca de 39 mil observaciones adicionales. La distribución de clases fue relativamente balanceada ($\approx 59\%$ alerta y 41% no alerta), por lo que no fue necesario aplicar técnicas de sobremuestreo.

Durante el análisis exploratorio se verificó que no existían valores faltantes y que las variables seguían distribuciones coherentes con el contexto del problema. También se observó que variables relacionadas con sueño ('V11', 'V10') tenían alta capacidad discriminante desde un análisis univariado. Se detectaron colas largas en variables como temperatura y consumo de alcohol, pero no valores imposibles o patológicos, por lo que se prefirió transformar las variables en lugar de eliminar observaciones.

3. Preparación de los datos e ingeniería de variables

La preparación de datos se enfocó principalmente en ingeniería de características. Las transformaciones se diseñaron buscando aumentar la información útil entregada al modelo y representar mejor la fatiga acumulada del conductor. Las variables más importantes fueron:

- $\text{sleep_minus_since} = V11 - V10$
- $\text{sleep_per_since} = V11 / (V10 + 0.5)$
- $\text{fatigue_alcohol} = V5 \times V8$
- $\text{speed_per_width} = V4 / P6$
- Transformaciones logarítmicas sobre variables con colas largas

Estas variables permitieron condensar relaciones fisiológicas complejas en representaciones más útiles para los modelos de boosting. Por ejemplo, 'sleep_per_since' captura simultáneamente las horas de sueño y el tiempo transcurrido desde el último descanso, convirtiéndose en la feature más importante del modelo final.

Para la regresión logística se aplicó estandarización Z-score, debido a que la regularización L2 es sensible a la escala de las variables. En contraste, los modelos basados en árboles fueron entrenados sin escalamiento, ya que LightGBM y XGBoost son invariantes a transformaciones monótonas.

4. Modelamiento e iteraciones de Kaggle

Primer sometimiento: submission.csv (0.98966)

El primer pipeline combinó regresión logística regularizada, XGBoost y dos variantes de LightGBM usando validación cruzada estratificada de 5 folds. La decisión de usar boosting se tomó porque el problema presentaba interacciones no lineales entre sueño, fatiga y condiciones ambientales que un modelo lineal no podía capturar completamente. Los modelos se combinaron mediante rank-average, técnica apropiada para ROC-AUC debido a que la métrica depende únicamente del orden relativo de las probabilidades.

Segundo sometimiento: submission_v2.csv (0.99005)

Después del primer resultado se verificó que no existiera overfitting mediante pruebas de permutación y análisis de estabilidad entre folds (AUC con target permutado = 0.49885, Var. entre folds: $\sigma = 0.0008$). Posteriormente se implementó seed bagging sobre LightGBM, entrenando múltiples modelos con semillas distintas y utilizando el 100% del dataset. Esta estrategia permitió reducir varianza y mejorar ligeramente la generalización del ensamble.

Tercer sometimiento: submission_v2_a_50_50.csv (0.99013)

En la tercera iteración se ajustaron los pesos del blend hacia una mezcla más equilibrada entre el modelo validado por cross-validation y el bagging full-data. El cambio fue pequeño, pero suficiente para obtener aun mejor score público, evitando el sobreajuste. La mejora confirma que, en problemas con datasets grandes y métricas tan sensibles como ROC-AUC, las reducciones marginales de varianza pueden representar diferencias importantes en el leaderboard.

Modelo / Sometimiento	ROC-AUC
submission.csv	0.98966
submission_v2.csv	0.99005
submission_v2_a_50_50.csv	0.99013

5. Evaluación y explicabilidad

La validación se realizó exclusivamente mediante predicciones out-of-fold, evitando leakage y garantizando una estimación honesta del desempeño. El modelo final alcanzó un OOF AUC de 0.98771 y un Public Score máximo de 0.99013 en Kaggle.

La explicabilidad del modelo se evaluó mediante feature importance de LightGBM. Las variables más relevantes fueron `sleep\_per\_since`, `V6` (temperatura), `P6` (amplitud de la vía), `sleep\_minus\_since` y `V11` (horas de sueño). Esto demuestra que el balance entre descanso y tiempo despierto es el principal determinante del nivel de alerta del conductor.

6. Conclusiones

El resultado final demuestra que una combinación de ingeniería de variables orientada al dominio del problema y métodos modernos de boosting puede superar ampliamente modelos lineales tradicionales. Las mejoras entre sometimientos surgieron principalmente de reducir la varianza

del ensamble y no de aumentar complejidad innecesaria. La utilización de validación cruzada estratificada, blending por rankings y bagging con múltiples semillas permitió obtener un modelo robusto, estable y competitivo.

Finalmente, el taller evidenció la importancia de un proceso iterativo de modelamiento en competencias de machine learning: pequeñas mejoras acumulativas en ingeniería de variables, ensamble y estabilidad del modelo pueden producir diferencias relevantes en métricas de alto nivel como ROC-AUC.