

PONTIFICIA UNIVERSIDAD JAVERIANA

ANÁLISIS DE REGRESIÓN — 2026-1

Factores asociados al desempeño académico en matemáticas: un análisis de regresión lineal múltiple

Juan David Manosalva

Juan Diego Carreño

17 de Marzo de 2026

Índice

1. Introducción	2
1.1. Descripción del conjunto de datos	2
2. Parte 1: Análisis previo de los datos	3
2.1. Distribución de la variable dependiente	3
2.2. Evaluación de transformaciones sobre Y	4
2.3. Dispersión entre Y y las variables continuas	5
2.4. Dispersión entre variables explicativas	6
2.5. Distribución de Y según variables categóricas	7
3. Parte 2: Estimación, ajuste y validación de modelos	9
3.1. Modelo 1: Modelo completo	10
3.2. Modelos 2 y 3: Diagnóstico de multicolinealidad	11
3.3. Modelo 4: Solo variables categóricas (contraste)	11
3.4. Modelo 5: Recodificación de <code>grupo_etnico</code> — Modelo Final	12
3.5. Modelo 6: Evaluación de parsimonia sin <code>educ_padres</code>	13
3.6. Comparación de bondad de ajuste	13
4. Validación de supuestos del modelo final	14
4.1. Supuesto 1 — Normalidad de los errores	14
4.2. Supuesto 2 — Homocedasticidad	15
4.3. Supuesto 3 — Multicolinealidad	17
4.4. Supuesto 4 — Independencia	17
5. Interpretación del modelo final	17
5.1. Predicción de ejemplo	19
6. Conclusiones	20

1. Introducción

El rendimiento académico en matemáticas es un indicador ampliamente reconocido del desempeño escolar general y un predictor relevante del acceso a la educación superior y al mercado laboral. Comprender qué factores determinan los puntajes en esta área permite orientar políticas educativas más focalizadas y diseñar intervenciones efectivas.

El presente informe analiza el conjunto de datos *Students Performance in Exams*, disponible públicamente en la plataforma Kaggle (<https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>). Este conjunto fue compilado con fines académicos y contiene información de 1 000 estudiantes de educación media en Estados Unidos, sin restricciones de privacidad.

Pregunta de investigación: ¿En qué medida el desempeño en pruebas de lectura y escritura, junto con características socioeconómicas y demográficas del estudiante, permiten predecir el puntaje obtenido en el examen de matemáticas?

Para responder esta pregunta se estima un modelo de regresión lineal múltiple mediante un proceso iterativo de seis especificaciones, partiendo del modelo completo con todas las variables disponibles hasta llegar al modelo con mejor equilibrio entre ajuste y parsimonia.

1.1. Descripción del conjunto de datos

Las **unidades estadísticas** son estudiantes de educación media en Estados Unidos. El conjunto de datos tiene estructura de **corte transversal**: todas las observaciones corresponden a un único momento de medición. La muestra cuenta con $n = 1\,000$ observaciones y no presenta valores faltantes en ninguna variable.

Tabla 1: Descripción de las variables del conjunto de datos

Variable	Tipo	Descripción	Escala / Categorías
punt_mate	Continua	Puntaje en matemáticas (Y)	0 – 100
punt_lect	Continua	Puntaje en lectura	0 – 100
punt_escr	Continua	Puntaje en escritura	0 – 100
genero	Categórica	Género del estudiante	Femenino / Masculino
grupo_etnico	Categórica	Grupo étnico	Grupos A, B, C, D, E
educ_padres	Categórica	Nivel educativo de los padres	6 niveles (ver texto)
almuerzo	Categórica	Tipo de programa de almuerzo	Subsidiado / Estándar
preparacion	Categórica	Curso de preparación para el examen	Sin prep. / Completó curso

Los seis niveles de **educ_padres**, de menor a mayor, son: bachillerato incompleto (categoría de referencia), bachillerato, algo de universidad, técnico, universitario y posgrado.

La variable **almuerzo** funciona como **proxy socioeconómico**: en el sistema escolar estadounidense, el almuerzo subsidiado se otorga a familias de bajos ingresos según umbrales federales, siendo una medida indirecta ampliamente utilizada del nivel socioeconómico del hogar.

2. Parte 1: Análisis previo de los datos

2.1. Distribución de la variable dependiente

La Figura 1 muestra la distribución empírica de **punt_mate**. Los estadísticos descriptivos son:

Media	Mediana	D.E.	Mínimo	Máximo	Ceros
66.09	66	15.16	0	100	1

La distribución es aproximadamente simétrica y unimodal. La curva de densidad empírica (rojo) sigue de cerca la normal teórica (verde discontinuo). La prueba de Shapiro-Wilk sobre Y marginal reporta $W = 0,993$, $p = 0,00015$, lo que representa un rechazo estadístico. Sin embargo, con $n = 1\,000$ la prueba tiene poder suficiente para detectar desviaciones mínimas que no comprometen la validez del modelo. Cabe aclarar que lo relevante para la inferencia es la normalidad de los *residuos del modelo*, no de Y marginal.




Figura 1: Distribución del puntaje en matemáticas. La densidad empírica (rojo) y la normal teórica (verde discontinuo) muestran un ajuste adecuado con ligera asimetría en las colas.

2.2. Evaluación de transformaciones sobre Y

Dado el único valor igual a cero en `punt_mate`, se evaluó la transformación $\log(Y + 0,5)$ para mejorar la normalidad. La Figura 2 compara ambas escalas.




Figura 2: Distribución de `punt_mate` en escala original (a) y tras transformación logarítmica (b). La curva roja es la normal teórica ajustada en cada caso.

La transformación logarítmica **empeora** la distribución: Shapiro-Wilk sobre $\log(Y + 0,5)$ arroja $W = 0,760$, $p < 2,2 \times 10^{-16}$, frente a $W = 0,993$ en escala original. Esto ocurre porque la distribución de puntajes acotada en $[0, 100]$ no presenta la asimetría positiva que típicamente justifica el uso del logaritmo.

Transformación de Y

La escala original es más compatible con la distribución normal que la transformación logarítmica. **Decisión:** se trabaja con Y en escala original. No se requiere transformación.

2.3. Dispersión entre Y y las variables continuas

Las Figuras 3 y 4 muestran la relación entre el puntaje en matemáticas y los puntajes en lectura y escritura. En ambos casos se superpone el ajuste lineal (rojo, con banda de confianza al 95 %) y la curva LOESS (verde discontinuo) para detectar posibles no linealidades.




Figura 3: Dispersión de `punt_mate` frente a `punt_lect` ($r = 0,818$). La curva LOESS sigue de cerca la recta lineal, confirmando una relación esencialmente lineal y positiva.




Figura 4: Dispersión de `punt_mate` frente a `punt_escr` ($r = 0,803$). Relación lineal y positiva similar a la observada con lectura, con dispersión moderada y homogénea a lo largo del rango.

En ambos gráficos la curva LOESS no exhibe curvatura sistemática apreciable, validando el **supuesto de linealidad** y descartando la necesidad de términos cuadráticos o transformaciones en las covariables continuas.

Hallazgo clave

Las correlaciones de `punt_mate` con `punt_lect` ($r = 0,818$) y con `punt_escr` ($r = 0,803$) son altas y positivas, con relaciones claramente lineales. No se requieren transformaciones en las covariables continuas.

2.4. Dispersión entre variables explicativas

La Figura 5 muestra la relación entre las dos covariables continuas, que resulta el hallazgo exploratorio más importante del análisis.




Figura 5: Dispersión entre puntaje en lectura y puntaje en escritura ($r = 0,955$). La correlación cuasi-perfecta anticipa multicolinealidad al incluir ambas variables simultáneamente.

Alerta de multicolinealidad

La correlación entre `punt_lect` y `punt_escr` es $r = 0,955$. Esta colinealidad elevada motivará el análisis de VIF en todos los modelos y la estimación de especificaciones alternativas donde se omite una de las dos variables (Modelos 2 y 3).

2.5. Distribución de Y según variables categóricas

La Figura 6 presenta los boxplots de `punt_mate` según género, grupo étnico, tipo de almuerzo y curso de preparación. La Figura 7 muestra el nivel educativo de los padres por separado.




Figura 6: Puntaje en matemáticas según género (a), grupo étnico (b), tipo de almuerzo (c) y curso de preparación (d). El diamante blanco representa la media grupal.




Figura 7: Puntaje en matemáticas según nivel educativo de los padres. Tendencia creciente débil con alta variabilidad intragrupo.

Las observaciones principales son:

- **Género:** Los estudiantes masculinos muestran una media de 68.73 frente a 63.63 de los femeninos.
- **Grupo étnico:** El grupo E sobresale visiblemente del resto (media = 73.82), mientras que los grupos A-D presentan medias similares entre sí (≈ 65 puntos).

Esta asimetría interna motivará una recodificación en el proceso iterativo.

- **Almuerzo:** Los estudiantes con almuerzo estándar obtienen en promedio 70.03 puntos frente a 58.92. Es la diferencia más pronunciada entre variables categóricas.
- **Preparación:** Descriptivamente, quienes completaron el curso tienen media de 69.70 vs. 64.08. Sin embargo, este efecto bruto se revierte al controlar por puntajes continuos (discutido en la Sección 3).
- **Educación de los padres:** Tendencia creciente débil, con alta variabilidad intragrupo que anticipa dificultades de significancia individual en el modelo.

La Figura 8 muestra la relación entre las variables categóricas `educ_padres` y `almuerzo`.




Figura 8: Proporción del tipo de almuerzo según nivel educativo de los padres. La fracción de almuerzo estándar (azul) crece con el nivel educativo, confirmando que ambas variables capturan el mismo gradiente socioeconómico.

La fracción de almuerzo estándar aumenta casi monótonamente con el nivel educativo de los padres, indicando que `almuerzo` y `educ_padres` capturan parcialmente el mismo fenómeno socioeconómico. No obstante, ambas conservan significancia conjunta en el modelo, por lo que se mantienen como regresores independientes.

3. Parte 2: Estimación, ajuste y validación de modelos

El proceso de estimación sigue un ciclo iterativo de seis especificaciones. Las primeras cuatro tienen carácter exploratorio o de diagnóstico; las dos últimas refinan la estructura del modelo completo. La Figura 9 y la Tabla 5 consolidan la comparación al final de esta sección.

Las **categorías de referencia** en todos los modelos son: género femenino, grupo étnico A, bachillerato incompleto, almuerzo subsidiado y sin preparación.

3.1. Modelo 1: Modelo completo

El modelo completo incluye las siete variables disponibles como punto de partida obligatorio del proceso iterativo:

$$\widehat{\text{punt_mate}} = \beta_0 + \beta_1 \text{punt_lect} + \beta_2 \text{punt_escr} + \beta_3 \mathbf{1}[\text{Masculino}] + \sum_{k \in \{B, C, D, E\}} \delta_k \mathbf{1}[\text{grupo } k] + \sum_{j=2}^6 \gamma_j \mathbf{1}[\text{educ. nivel } j] + \beta_4 \mathbf{1}[\text{Alm. Estándar}] + \beta_5 \mathbf{1}[\text{Completó curso}] + \varepsilon \quad (1)$$

Los resultados se presentan en la Tabla 2.

Tabla 2: Estimación — Modelo 1 (completo). $n = 1,000$, $R^2 = 0,877$, $R^2_{\text{adj}} = 0,875$, $\text{RSE} = 5,362$, $\text{AIC} = 6,213,4$

Variable	Estimación	Std. Error	Valor t	p -valor
(Intercepto)	-7,550	1.082	-6,980	< 0,001
punt_lect	0,264	0.042	6,266	< 0,001
punt_escr	0,702	0.044	16,120	< 0,001
Género: Masculino	13,240	0.372	35,599	< 0,001
Grupo étnico B	0,835	0.692	1,207	0,228
Grupo étnico C	0,178	0.649	0,275	0,784
Grupo étnico D	0,098	0.670	0,147	0,883
Grupo étnico E	5,078	0.737	6,888	< 0,001
Educ. padres: Bachillerato	0,016	0.559	0,028	0,978
Educ. padres: Algo de univ.	-0,152	0.547	-0,278	0,781
Educ. padres: Técnico	-0,552	0.550	-1,004	0,316
Educ. padres: Universitario	-1,599	0.657	-2,434	0,015
Educ. padres: Posgrado	-2,408	0.828	-2,910	0,004
Almuerzo: Estándar	3,213	0.374	8,585	< 0,001
Preparación: Completó curso	-3,502	0.397	-8,831	< 0,001

Prueba F global: $F(14, 985) = 500,3$, $p < 2,2 \times 10^{-16}$. Se rechaza contundentemente $H_0 : \beta_1 = \dots = \beta_{14} = 0$. El modelo es altamente significativo en conjunto.

Significancia individual: Los grupos étnicos B, C y D no son individualmente significativos, ni tampoco los niveles Bachillerato, Algo de universidad y Técnico de educ_padres. Sin embargo, la no significancia individual no implica eliminar la variable; es necesario evaluar el aporte conjunto mediante pruebas F parciales.

Prueba F parcial sobre grupo_etnico: $F(4, 985) = 24,16$, $p < 0,0001$. La variable es significativa conjuntamente gracias al grupo E. **No se elimina.**

Prueba F parcial sobre educ_padres: $F(5, 985) = 3,07$, $p = 0,009$. La variable también aporta significativamente. **No se elimina.**

Diagnóstico VIF: La Tabla 3 muestra el VIF escalado $\text{GVIF}^{1/(2\text{Df})}$ para cada variable. Los valores de `punt_lect` (3,62) y `punt_escr` (3,90) están por encima del umbral de alerta de 2, pero por debajo del límite crítico de 5, confirmando la multicolinealidad moderada anticipada en el análisis exploratorio.

Tabla 3: VIF escalado — Modelo 1. Umbral de alerta: > 2 ; problema serio: > 5 .

Variable	Df	GVIF	$\text{GVIF}^{1/(2\text{Df})}$
<code>punt_lect</code>	1	13.10	3.62
<code>punt_escr</code>	1	15.20	3.90
<code>genero</code>	1	1.20	1.10
<code>grupo_etnico</code>	4	1.12	1.01
<code>educ_padres</code>	5	1.17	1.02
<code>almuerzo</code>	1	1.12	1.06
<code>preparacion</code>	1	1.26	1.12

3.2. Modelos 2 y 3: Diagnóstico de multicolinealidad

Para investigar el impacto de la colinealidad entre los puntajes continuos, se estiman dos especificaciones que omiten una de ellas.

Modelo 2 (sin `punt_escr`): El VIF de `punt_lect` cae de 3,62 a 1,29, eliminando la colinealidad. Sin embargo, R_{adj}^2 cae de 0,875 a 0,842 y el AIC sube de 6,213 a 6,446.

Modelo 3 (sin `punt_lect`): $R_{\text{adj}}^2 = 0,870$, más cercano al modelo completo, con AIC = 6,251.

Estos resultados son concluyentes: **ambas covariables continuas aportan varianza explicada única e irreemplazable**. Aunque están altamente correlacionadas, cada una captura un componente diferente del desempeño académico. El nivel de VIF en M1 no supera el límite crítico de 5 y no invalida la inferencia. **Decisión: se mantienen ambas variables en el modelo.**

3.3. Modelo 4: Solo variables categóricas (contraste)

Para dimensionar la contribución marginal de los puntajes continuos, se estima un modelo con únicamente las cinco variables categóricas. El resultado es $R_{\text{adj}}^2 = 0,246$ y $\text{RSE} = 13,17$, comparado con 0,875 y 5,36 del modelo completo.

Las variables demográficas y socioeconómicas solas explican apenas el 25 % de la varianza. El poder predictivo reside fundamentalmente en los puntajes académicos previos.

3.4. Modelo 5: Recodificación de grupo_etnico — Modelo Final

En M1, el grupo E es el único nivel de `grupo_etnico` significativo ($\hat{\delta}_E = 5,08$, $p < 0,0001$), mientras que los grupos B, C y D tienen coeficientes cercanos a cero y p-valores entre 0,23 y 0,88. Toda la heterogeneidad de la variable se concentra en la distinción entre el grupo E y el resto.

Se recodifica `grupo_etnico` en una variable binaria:

$$\text{grupo_E} = \begin{cases} 1 & \text{si el estudiante pertenece al grupo E} \\ 0 & \text{si pertenece a los grupos A, B, C o D} \end{cases}$$

Esta recodificación reduce de cuatro a una las dummies de grupo étnico, ahorrando tres grados de libertad. La validez estadística se confirma con la prueba F anidada M5 vs. M1: $F(3, 985) = 0,88$, $p = 0,451$. El modelo recodificado **no es significativamente peor** que el completo; la simplificación es estadísticamente válida.

Tabla 4: Estimación — Modelo 5 (Final). $n = 1,000$, $R^2 = 0,876$, $R^2_{\text{adj}} = 0,875$, $\text{RSE} = 5,361$, $\text{AIC} = 6,210,1$

Variable	Coef.	Std. Error	Valor t	p -valor	
(Intercepto)	-2,405	1.107	-2,173	0,030	*
punt_lect	0,269	0.041	6,503	< 0,001	***
punt_escr	0,695	0.043	16,338	< 0,001	***
Género: Masculino	13,192	0.368	35,816	< 0,001	***
grupo_E: Grupos A-D	-4,796	0.495	-9,698	< 0,001	***
Educ. padres: Bachillerato	0,053	0.557	0,095	0,924	
Educ. padres: Algo de univ.	-0,154	0.546	-0,282	0,778	
Educ. padres: Técnico	-0,531	0.547	-0,971	0,332	
Educ. padres: Universitario	-1,587	0.655	-2,423	0,016	*
Educ. padres: Posgrado	-2,444	0.826	-2,959	0,003	**
Almuerzo: Estándar	3,232	0.374	8,654	< 0,001	***
Preparación: Completó curso	-3,463	0.393	-8,817	< 0,001	***

*** $p < 0,001$, ** $p < 0,01$, * $p < 0,05$. Ref.: Femenino, Grupo E, Bach. inc., Subsidiado, Sin preparación.

Prueba F global M5: $F(11, 988) = 636,7$, $p < 2,2 \times 10^{-16}$.

3.5. Modelo 6: Evaluación de parsimonia sin educ_padres

Dado que tres de los cinco niveles de `educ_padres` no son individualmente significativos en M5, se evalúa si la variable puede suprimirse. La prueba F anidada M6 vs. M5 arroja $F(5, 988) = 3,15$, $p = 0,008$, rechazando la exclusión. Los niveles Universitario y Posgrado contribuyen significativamente y la variable aporta en conjunto. **Decisión:** `educ_padres` se conserva en el modelo final.

3.6. Comparación de bondad de ajuste

Tabla 5: Comparación de bondad de ajuste entre los seis modelos estimados

ID	Descripción	R^2	R^2_{adj}	RSE	AIC	BIC
M1	Completo	0.877	0.875	5.362	6213.4	6291.9
M2	Sin <code>punt_escr</code>	0.844	0.842	6.025	6445.5	6519.2
M3	Sin <code>punt_lect</code>	0.872	0.870	5.465	6250.5	6324.1
M4	Solo categóricas	0.255	0.246	13.169	8008.5	8077.2
M5	grupo_E binario (Final)	0.876	0.875	5.361	6210.1	6273.9
M6	M5 sin <code>educ_padres</code>	0.874	0.874	5.390	6215.9	6255.2




Figura 9: Comparación de modelos por R^2 ajustado (a) y AIC (b). El modelo seleccionado M5 (en azul) presenta el AIC más bajo con igual R^2_{adj} que el modelo completo M1.

M5 es el modelo seleccionado con base en los siguientes criterios:

- AIC mínimo ($6,210,1 < 6,213,4$ de M1).
- Igual R^2_{adj} que M1 (0,875): sin pérdida de ajuste.
- Igual RSE que M1 (5,361): sin aumento en el error de predicción.
- Mayor parsimonia: 12 coeficientes frente a 15 de M1.
- Test F anidado M5 vs. M1 no rechaza la equivalencia ($p = 0,451$).

4. Validación de supuestos del modelo final

4.1. Supuesto 1 — Normalidad de los errores

La prueba de Shapiro-Wilk sobre los residuos del Modelo 5 reporta $W = 0,998$, $p = 0,481$: no se rechaza normalidad. Este resultado es favorable dado que con $n = 1\,000$ la prueba tiene alto poder para detectar incluso desviaciones menores. Las Figuras 10 y 11 confirman el resultado visualmente.




Figura 10: QQ-Plot de residuos del Modelo Final (M5). Los puntos siguen la línea de referencia sin desviaciones sistemáticas en las colas, confirmando normalidad.




Figura 11: Histograma de residuos del Modelo Final (M5) con densidad empírica (rojo) y normal teórica (verde discontinuo). La distribución es simétrica, centrada en cero, compatible con la normal.

Supuesto 1 — Normalidad

Se satisface. Shapiro-Wilk: $W = 0,998$, $p = 0,481$. QQ-Plot e histograma de residuos son consistentes con la distribución normal.

4.2. Supuesto 2 — Homocedasticidad

La prueba de Breusch-Pagan arroja $BP = 15,28$, $gl = 11$, $p = 0,170$: no se rechaza varianza constante. Las Figuras 12 y 13 confirman visualmente la ausencia de patrones sistemáticos.




Figura 12: Residuos estandarizados frente a valores ajustados — M5. Distribución aleatoria alrededor de cero sin patrón en abanico, confirmando homocedasticidad.




Figura 13: Gráfico Scale-Location — M5. La línea LOESS (rojo) es aproximadamente horizontal, confirmando varianza constante.

Supuesto 2 — Homocedasticidad

Se satisface. Breusch-Pagan: $p = 0,170$. Los gráficos de diagnóstico no muestran patrones de heterocedasticidad.

4.3. Supuesto 3 — Multicolinealidad

Tabla 6: VIF escalado $\text{GVIF}^{1/(2\text{Df})}$ — Modelo Final M5

Variable	Df	GVIF	$\text{GVIF}^{1/(2\text{Df})}$
punt_lect	1	12.69	3.56
punt_escr	1	14.51	3.81
genero	1	1.18	1.09
grupo_E	1	1.02	1.01
educ_padres	5	1.15	1.01
almuerzo	1	1.11	1.05
preparacion	1	1.23	1.11

Los valores de `punt_lect` (3,56) y `punt_escr` (3,81) permanecen por debajo del límite crítico de 5. Ambas son altamente significativas con coeficientes estables a través de las especificaciones. La multicolinealidad moderada infla levemente sus errores estándar, pero **no compromete la validez de la inferencia**. Para las demás variables, los valores son cercanos a 1.

4.4. Supuesto 4 — Independencia

El conjunto de datos tiene estructura de corte transversal: 1 000 estudiantes distintos medidos en un mismo periodo, sin estructura temporal ni de conglomerados conocida. **El supuesto de independencia se cumple por diseño.**

5. Interpretación del modelo final

El modelo final (M5) toma la forma:

$$\widehat{\text{punt_mate}} = -2,405 + 0,269 \text{punt_lect} + 0,695 \text{punt_escr} + 13,192 \mathbf{1}[\text{Masc.}] \\ - 4,796 \mathbf{1}[\text{GruposA-D}] + \hat{\gamma}' \mathbf{d}_{\text{educ}} + 3,232 \mathbf{1}[\text{Alm.Est.}] - 3,463 \mathbf{1}[\text{Completó}] \quad (2)$$

La Tabla 7 presenta los intervalos de confianza al 95 %.

Tabla 7: Intervalos de confianza al 95 % — Modelo Final (M5)

Variable	L.I. 2.5 %	L.S. 97.5 %	¿Contiene 0?
(Intercepto)	-4,578	-0,233	No
punt_lect	0,188	0,350	No
punt_escr	0,611	0,778	No
Género: Masculino	12,469	13,915	No
grupo_E: Grupos A-D	-5,766	-3,825	No
Educ. padres: Bachillerato	-1,040	1,146	Sí
Educ. padres: Algo de univ.	-1,225	0,917	Sí
Educ. padres: Técnico	-1,605	0,542	Sí
Educ. padres: Universitario	-2,872	-0,302	No
Educ. padres: Posgrado	-4,065	-0,823	No
Almuerzo: Estándar	2,499	3,965	No
Preparación: Completó curso	-4,234	-2,693	No

Se interpreta cada coeficiente manteniendo las demás variables constantes (*ceteris paribus*):

Puntaje en lectura ($\hat{\beta}_1 = 0,269$): Por cada punto adicional en lectura, el puntaje en matemáticas aumenta en promedio 0,269 puntos. El IC [0,188, 0,350] excluye el cero. Un incremento de 10 puntos en lectura equivale a +2,69 puntos en matemáticas.

Puntaje en escritura ($\hat{\beta}_2 = 0,695$): Es el regresor continuo con mayor efecto marginal: por cada punto adicional en escritura, el puntaje en matemáticas aumenta en promedio 0,695 puntos. Un incremento de 10 puntos en escritura equivale a +6,95 puntos.

Género masculino ($\hat{\beta}_3 = 13,192$): Controlando por todas las demás variables, los estudiantes masculinos obtienen en promedio 13,19 puntos más que los femeninos. El IC [12,47, 13,92] es estrecho y no contiene el cero. Esta brecha persiste controlando por habilidades académicas, indicando que no se explica enteramente por diferencias en lectura y escritura.

Grupos A-D ($\hat{\delta} = -4,796$): Los estudiantes de los grupos A-D obtienen en promedio 4,80 puntos menos que los del grupo E. El IC [-5,77, -3,83] es enteramente negativo, señalando una brecha diferencial robusta del grupo E respecto a todos los demás.

Nivel educativo de los padres: Solo los niveles Universitario ($-1,587$, $p = 0,016$) y Posgrado ($-2,444$, $p = 0,003$) son significativamente distintos de la referencia. El signo negativo refleja que, una vez controlados los puntajes de lectura y escritura, tener padres más educados no se traduce en un puntaje adicional por encima del ya explicado por el desempeño académico previo del estudiante.

Almuerzo estándar ($\hat{\beta}_4 = 3,232$): Los estudiantes con almuerzo estándar obtienen en

promedio 3,23 puntos adicionales. El IC [2,50, 3,97] es positivo y estrecho, capturando efectos del contexto socioeconómico familiar no absorbidos por el nivel educativo de los padres.

Completó curso de preparación ($\hat{\beta}_5 = -3,463$):

Efecto contra-intuitivo del curso de preparación

Descriptivamente, quienes completaron el curso obtienen una media de 69,70 frente a 64,08 (diferencia bruta de +5,62 puntos). Sin embargo, el coeficiente del modelo es $-3,46$ ($p < 0,0001$). Esta inversión de signo se explica por **sesgo de selección**: los estudiantes que se inscriben al curso son en promedio quienes parten de menores puntajes en lectura y escritura. Al controlar por esos puntajes previos, el efecto neto resulta negativo. El modelo no implica que el curso *cause* menor rendimiento; indica que, igualados los perfiles académicos previos, los estudiantes que completaron el curso puntúan por debajo de lo esperado para su nivel. Este es un ejemplo clásico de la diferencia entre efectos brutos y controlados en regresión múltiple.

5.1. Predicción de ejemplo

Para ilustrar el uso del modelo, se estima el puntaje esperado de un estudiante masculino del grupo E, con lectura = 70, escritura = 65, padres universitarios, almuerzo estándar y que completó el curso:

$$\hat{y} = -2,405 + 0,269(70) + 0,695(65) + 13,192 + 0 + (-1,587) + 3,232 + (-3,463) = \mathbf{72,96}$$

Tabla 8: Predicción puntual e intervalos al 95 % para el estudiante de ejemplo

	Límite inferior	Límite superior
Estimación puntual	72.96	
Intervalo de confianza 95 % (media)	71.47	74.45
Intervalo de predicción 95 % (individuo)	62.33	83.59

El intervalo de confianza [71,47, 74,45] es estrecho (3 puntos), reflejando la precisión del modelo para la media de estudiantes con ese perfil. El intervalo de predicción individual [62,33, 83,59] es más amplio, capturando la variabilidad individual no explicada por el modelo.

6. Conclusiones

A través de un proceso iterativo de seis especificaciones se estimó un modelo de regresión lineal múltiple para el puntaje en matemáticas de 1 000 estudiantes. Los hallazgos principales son:

1. **Las habilidades académicas previas son el principal determinante.** Al excluir los puntajes de lectura y escritura, R^2_{adj} cae de 0,875 a 0,246. Las relaciones son lineales y no requieren transformaciones.
2. **El género tiene el mayor efecto individual.** La brecha de 13,19 puntos a favor de los estudiantes masculinos persiste incluso controlando por habilidades académicas.
3. **El contexto socioeconómico importa independientemente.** El almuerzo estándar (proxy socioeconómico) mantiene un efecto positivo de 3,23 puntos después de controlar por habilidades académicas, nivel educativo de los padres y demás covariables.
4. **La recodificación del grupo étnico es estadísticamente válida y mejora la parsimonia.** El grupo E concentra toda la heterogeneidad relevante; la variable binaria resultante tiene el mismo poder explicativo que las cuatro dummies originales (test F anidado: $p = 0,451$).
5. **El curso de preparación ilustra el sesgo de selección.** El signo negativo del coeficiente multivariado vs. el efecto bruto positivo es un ejemplo pedagógicamente valioso de la necesidad de controlar por variables de confusión en regresión múltiple.
6. **Todos los supuestos del modelo clásico se cumplen.** Normalidad ($p = 0,481$), homocedasticidad ($p = 0,170$), $\text{VIF} < 5$ en todas las variables e independencia por diseño.

El modelo final (M5) captura el 87.5 % de la varianza del puntaje en matemáticas con 12 parámetros y un error estándar residual de 5,36 puntos.

Fuente de datos: Students Performance in Exams. Kaggle — spscientist. <https://www.kaggle.com/datasets/spscientist/students-performance-in-exams>. **Software:** R 4.3.3. **Paquetes:** dplyr, ggplot2, car, lmtest.